

CART

Muyao GUO

2025-10-07

```
rm(list=objects())      # supprime les objets existant en session
graphics.off()          # supprime les graphiques existant en session
# définit le répertoire en cours, à compléter

library(rpart)
# Library(ggplot2)
library(rpart.plot)

#####
#####

tumeur=read.table("mammographic.data",header=T)

str(tumeur)


## 'data.frame':   830 obs. of  5 variables:
## $ age     : int  67 58 28 57 76 42 36 60 54 52 ...
## $ shape   : int  3 4 1 1 1 2 3 2 1 3 ...
## $ margin  : int  5 5 1 5 4 1 1 1 1 4 ...
## $ density: int  3 3 3 3 3 3 2 2 3 3 ...
## $ Y       : int  1 1 0 1 1 1 0 0 0 0 ...

table(tumeur$shape)

##
##    1    2    3    4
## 190 180  81 379

hist(tumeur$age)
```

Histogram of tumeur\$age



```
summary(tumeur$density)
##      Min. 1st Qu. Median      Mean 3rd Qu.      Max.
## 1.000   3.000   3.000   2.916   3.000   4.000
# 1     2     3     4
# 11   56  755    8

#####
# Les covariables autres que age sont discrètes : facteurs dans R
```

```
tumeur$shape=factor(tumeur$shape)
tumeur$margin=factor(tumeur$margin)
tumeur$density=factor(tumeur$density)
tumeur$Y=factor(tumeur$Y)

#####
```

Q1

```
dim(tumeur) # 4 covariables pour 830 individus
## [1] 830   5
# $Y$ est binaire: modèle de classification
table(tumeur$Y)
```

```

##          0      1
## 427 403

# 0      1
# 427 403
# Les nb de cas positifs/négatifs sont équilibrés
sum(tumeur$Y==1)/length(tumeur$Y)


## [1] 0.4855422
# 0.4855422 49% de lésions malignes

#### Q2

t.rpart=rpart(Y~., data = tumeur)
# rpart.plot(t.rpart)
# par défaut minsplit=20 et cp=0.01

plot(t.rpart)
text(t.rpart)

```



```

print(t.rpart) # savoir lire cet arbre sans figure

## n= 830
##
## node), split, n, loss, yval, (yprob)

```

```

##      * denotes terminal node
##
## 1) root 830 403 0 (0.5144578 0.4855422)
##   2) margin=1 320 38 0 (0.8812500 0.1187500) *
##   3) margin=2,3,4,5 510 145 1 (0.2843137 0.7156863)
##     6) shape=2 54 17 0 (0.6851852 0.3148148) *
##     7) shape=1,3,4 456 108 1 (0.2368421 0.7631579)
##       14) age< 53.5 118 48 1 (0.4067797 0.5932203)
##         28) shape=1,3 25 8 0 (0.6800000 0.3200000) *
##         29) shape=4 93 31 1 (0.3333333 0.6666667) *
##       15) age>=53.5 338 60 1 (0.1775148 0.8224852) *

```

Il y a 5 feuilles

1) root 830 403 0 (0.5144578 0.4855422)

le noeud racine contient 830 observations dont 403 positifs (lésions malignes)

la classe majoritaire est 0 (tumeurs bénignes) avec une proportion de 51%

noeud droit sous la racine

3) margin=2,3,4,5 510 145 1 (0.2843137 0.7156863)

ce noeud contient 510 observations dont 145 positifs;


la classe majoritaire est 1 (tumeurs malignes) avec une proportion de 72%

La valeur de CP (par défaut 0.1) pénalise des arbres plus profonds et

fournit ici un arbre à 5 feuilles; sur la branche gauche, le gain d'impureté calculé n'est pas suffisant pour créer un split (si l'on diminue minsplit, cela ne modifie pas l'arbre)

Tracé amélioré

```
rpart.plot(t.rpart)
```



```

#### Q3 arbre CART
set.seed(12345)

# On commence par calculer un arbre maximal
tmax <- rpart(Y~., data = tumeur,
                 control = rpart.control(cp = 0,minsplit=3))

# On affiche la table qui fournit les valeurs du paramètre de complexité CP
# associées à une suite de sous-arbres
# compris entre l'arbre racine et l'arbre maximal de l'étape précédente

printcp(tmax)


##
## Classification tree:
## rpart(formula = Y ~ ., data = tumeur, control = rpart.control(cp = 0
## ,
##     minsplit = 3))
##
## Variables actually used in tree construction:
## [1] age      density margin   shape
## 
## Root node error: 403/830 = 0.48554
## 
## n= 830
  
```

```

##          CP nsplit rel.error xerror      xstd
## 1  0.54590571     0   1.00000 1.00000 0.035729
## 2  0.04962779     1   0.45409 0.45409 0.029637
## 3  0.01116625     2   0.40447 0.42184 0.028850
## 4  0.00744417     4   0.38213 0.43176 0.029099
## 5  0.00496278     6   0.36725 0.43176 0.029099
## 6  0.00372208     7   0.36228 0.40943 0.028530
## 7  0.00330852     9   0.35484 0.41935 0.028787
## 8  0.00248139    12   0.34491 0.42184 0.028850
## 9  0.00165426    30   0.30025 0.42432 0.028913
## 10 0.00148883    44   0.27295 0.42680 0.028976
## 11 0.00124069    49   0.26551 0.44913 0.029520
## 12 0.00082713    76   0.22829 0.44913 0.029520
## 13 0.00062035    82   0.22333 0.44417 0.029402
## 14 0.00035448    86   0.22084 0.46402 0.029866
## 15 0.00000000    93   0.21836 0.46402 0.029866

```

`plotcp(tmax)`



la valeur de CP optimale correspond au sous-arbre qui réalise le meilleur compromis biais/variance pour éviter le sur-apprentissage.

on choisit la valeur qui minimise l'erreur de classification (ici taux de mal classés) estimé par validation croisée.

cette estimation est fournie en colonne 4 "xerror" (dans une version renormalisée)

```

# L'arbre cart est l'arbre élagué à la valeur de cp qui rend le taux de
# mal classés minimal
which.min(tmax$cptable[, 4])

## 6
## 6


# 6 --> Ligne 6 correspondant à nsplit=7 soit 7 noeuds internes ou 8 feuilles
tmax$cptable[which.min(tmax$cptable[, 4]), 1]

## [1] 0.003722084

# cp= 0.003722084 pour ce run de validation croisée

# on élague l'arbre maximal pour afficher l'arbre CART
tcart <- prune(tmax, cp = tmax$cptable[which.min(tmax$cptable[, 4]), 1])
) 
rpart.plot(tcart)

```



```

newdata1 <- data.frame(age=50,shape="3",margin="2",density="1")

predict(tcart, newdata = newdata1,type="class")

```

```
## 1
## 0
## Levels: 0 1

# 0 La prédiction est une lésion bénigne
# savoir retrouver cette prédiction dans l'arbre

prob = predict(tcart, newdata = newdata1)
#          0      1
# 1 0.68 0.32 probabilité d'une tumeur maligne estimée à 32%
```